

İstanbul Raylı Sistemler Yolcu Analizi (2021-2025)

Veri Bilimi Dönem Projesi

Tema: Akıllı Şehir & Toplu Taşıma
Veri Kaynağı: İBB Açık Veri Portalı — Mobilite Kategorisi
Lisans: İstanbul Büyükşehir Belediyesi Açık Veri Lisansı
Teslim Tarihi: 3 Temmuz 2026 — Bireysel Proje

1. Problem Tanımı ve Araştırma Soruları

İstanbul, günlük milyonlarca yolcunun raylı sistemleri kullandığı bir mega şehirdir. Bu proje, İBB Açık Veri Portalı'ndaki 4 farklı veri setini birleştirerek İstanbul raylı sistemlerinin çok boyutlu bir analizini sunmayı amaçlamaktadır. Zamansal, mekansal, altyapısal ve ağsal boyutlar bir arada incelenmiştir.

Araştırma Soruları

- RQ1 — Mevsimsellik:** Raylı sistemlerde mevsimsellik ve haftanın günü etkisi nedir? Hat tipleri (Metro/Tramvay/Füniküler) farklı zamansal profiller gösterir mi?
- RQ2 — Altyapı-Talep:** İstasyonun fiziksel özellikleri (büyüklük, yürüyen merdiven, asansör) günlük yolcu trafiğini ne ölçüde açıklar? Altyapıdan talep tahmini yapılabilir mi?
- RQ3 — İstasyon Tipolojisi:** İstasyonlar altyapı, lokasyon ve yolcu profiline göre nasıl kümelenir? Aktarma istasyonları ayrı bir tip oluşturur mu?
- RQ4 — Mekansal Dağılım:** Yolcu yoğunluğu İstanbul coğrafyasında nasıl dağılıyor? Hangi ilçeler/metro aksları baskın?
- RQ5 — Hat Verimliliği:** Km başına düşen yolcu sayısı hangi hatlarda en yüksek? En verimsiz hat hangisi? Yatırım önceliklendirmesi için ne söyler?

2. Veri Setleri

Tüm veriler İBB Açık Veri Portalı Mobilite kategorisinden, İstanbul Büyükşehir Belediyesi Açık Veri Lisansı altında alınmıştır. Dört veri seti istasyon ve hat bazında birleştirilmiştir.

Kod	Veri Seti	Boyut	Format	İçerik
A	Raylı Sistemler Yolcu ve Yolculuk Sayıları	544K satır	5x CSV	2021-2025 günlük geçiş/yolcu, GPS, 22 hat
B	Raylı Sistemlere Ait İstasyon Bilgileri	178 istasyon	1x XLSX	Büyüklük, yürüyen merdiven, asansör sayısı
C	Raylı Sistemlere Ait Hat Uzunluk Bilgileri	242 segment	1x XLSX	Hat segment bazında metre uzunluk
D	Raylı Sistemlere Ait Aktarma Bilgileri	97 bağlantı	1x XLSX	Hangi istasyonda hangi hatta aktarma

3. Yöntem

Proje 8 bölümlük bir Jupyter notebook (25 kod hücresi) üzerinde yürütülmüştür. Veri yüklemede 5 farklı CSV formatı (virgül/noktalı virgül delimiter, UTF-8 BOM, Latin-1 encoding) ve 3 XLSX dosyası işlenmiştir. Hat isimleri regex ile normalize edilmiş ("M1-YENIKAPI-HAVALIMANI" → "M1"), istasyon isimleri için difflib fuzzy matching uygulanmıştır. Bozuk GPS koordinatları (Türkçe locale kaynaklı format hataları) özel bir düzeltme fonksiyonu ile onarılmıştır.

İki model kullanılmıştır: (1) Altyapı özelliklerinden günlük yolcu tahmini için Linear Regression (StandardScaler, %80/20 split, R²/MAE/RMSE metrikleri), (2) İstasyon tipolojisi için K-Means kümeleme (PCA 2B görselleştirme, Elbow + Silhouette ile K=2-9 taranarak optimal K seçimi). Coğrafi analizde Folium interaktif haritası (338 istasyon, renk=hat tipi, tıklanabilir popup) ve matplotlib geo-scatter kullanılmıştır. Eksik veri analizi için missingno matrisi, yürüyen merdiven başına yolcu (passanger_per_merdiven) gibi türetilmiş değişkenler eklenmiştir.

Temel Metrikler

Toplam Veri
544.015 satır

Final Veri Seti
455.659 satır

Kapsam
2021-2025

İstasyon
338 unique

Hat
22 hat

4. Bulgular

RQ1 — Mevsimsellik ve Zamansal Profiller

Haftasonu ortalama yolcu geçişi hafta içine göre %24.1 daha düşüktür (hafta içi: 10.526, haftasonu: 7.988 geçiş/gün). Bu fark, raylı sistem kullanımının ağırlıklı olarak iş ve eğitim amaçlı olduğunu göstermektedir. Yaz aylarında (Temmuz-Ağustos) genel bir düşüş gözlenmekte, bu tatil ve okul etkisiyle açıklanabilir. Metro hatları hem toplam yolcu hacminde (%52) hem büyüme oranında liderdir. 2021'den 2025'e tüm hat tiplerinde pandemi sonrası toparlanma trendi görülmektedir. Aylık trend lineplot'u ve gün×ay heatmap'i bu örüntüleri görsel olarak doğrulamaktadır.

RQ2 — Altyapı ve Talep İlişkisi (Regresyon)

Linear Regression modeli altyapı özellikleriyle günlük yolcu sayısındaki varyansın %13.7'sini açıklamaktadır ($R^2 = 0.137$, MAE = 5.980, RMSE = 8.197 geçiş, RMSE/Ortalama = %79.1). Standardize edilmiş katsayılar göre en güçlü pozitif belirleyici aktarma istasyonu olma durumudur (+2.742). Haftasonu olumsuz etki göstermektedir (-1.555). İstasyon büyüklüğünün negatif katsayı göstermesi (-2.029) çoklu bağlantıya (multicollinearity) işaret etmektedir — büyük istasyonlar her zaman en yoğun istasyonlar değildir. Bu durum, altyapı-trafik ilişkisinin doğrusal olmadığını ve Random Forest/XGBoost gibi modellere ihtiyaç duyulduğunu göstermektedir.

RQ3 — İstasyon Tipolojisi (K-Means Kümeleme)

Optimal küme sayısı Silhouette analizi ile K=6 olarak belirlenmiştir (Silhouette = 0.372, orta düzeyde ayrışma). PCA ile 2 boyuta indirgenmiş görselleştirme kümeler arası belirgin bir yapı olduğunu göstermektedir.

- Küme 0 — Aktarma Hub'ları (20 istasyon): %100 aktarma, 13.089 geçiş/gün, 1.932 m²
- Küme 1 — Büyük İstasyonlar (28): 14.366 m², 15.1 merdiven, aktarma yok
- Küme 3 — Mega Hub'lar (12): 18.098 geçiş/gün, 16.631 m², 24 merdiven, %80 aktarma
- Küme 4 — Terminal Sınıfı (2): 83.212 m², 38 merdiven — benzersiz ölçek
- Küme 2 ve 5 — Mahalle/Semt Durakları (47+57): 1.196-2.543 m², düşük-orta trafik

RQ4 — Mekansal Dağılım

En yoğun istasyonlar Tarihi Yarımada (Yenikapı, Sirkeci, Aksaray) ve Anadolu Yakası geçiş noktalarında (Kadıköy, Üsküdar, Ayrılık Çeşmesi) yoğunlaşmaktadır. Marmaray hattı Avrupa-Asya arası ana omurgadır. Folium interaktif haritasında 338 istasyonun konumu, yolcu hacmiyle orantılı büyüklükte ve hat tipine göre renklendirilmiş olarak görselleştirilmiştir. İlçe bazında Fatih, Kadıköy ve Üsküdar en yüksek yolcu hacmine sahiptir.

RQ5 — Hat Verimliliği

Füniküler hatlar km başına en yüksek yolcu yoğunluğuna sahiptir (kısa hat + yüksek talep). Tramvay hatları da verimlilikte üst sıralardadır. Metro hatları toplam yolcu hacminde lider olsa da (M1: ~39 milyon/yıl, Marmaray: ~33 milyon/yıl), km başına verimlilikte orta sıralardadır. Bu metrik yatırım önceliklendirmesi için doğrudan kullanılabilir: kısa ama yüksek talep gören koridorlara yatırım, uzun düşük yoğunluklu koridorlara göre daha yüksek getiri sağlayabilir.

5. Sınırlamalar

- **Merge kayıpları:** Hat ve istasyon ismi eşleştirme tam olmadı; fuzzy matching ile eşleşme oranı %48.3'te kaldı. İBB'nin veri setleri arasındaki isimlendirme tutarsızlığı ana nedendir.
- **Veri kalitesi:** CSV formatları yıllar arası tutarsız (farklı delimiter, encoding, sütun sırası). 2021 ve 2024'te veri turnike bazında olduğu için istasyon bazına gruplanmıştır — bu işlem bilgi kaybına yol açmış olabilir.
- **Eksik değişkenler:** Nüfus yoğunluğu, turizm verisi, özel gün/etkinlik takvimi, hava durumu, saatlik yolcu dağılımı gibi dışsal faktörler modele dahil edilmemiştir. GTFS verisi entegrasyonu sefer sıklığı analizini mümkün kılabilirdi.
- **Model basitliği:** Kullanılan Linear Regression ($R^2=0.137$) ve K-Means (Silhouette=0.372) yorumlanabilir ancak basit modellerdir. Random Forest, XGBoost, DBSCAN veya SARIMA/Prophet gibi modeller daha iyi performans gösterebilir.
- **passage vs passanger farkı:** passage_cnt turnike geçiş sayısını, passanger_cnt tekil yolcu sayısını ifade eder. Aktarma yapan yolcular birden fazla geçiş üretir — bu fark özellikle aktarma istasyonlarında belirgindir.

6. Öğrenilenler

- **Gerçek dünya verisi dağınıktır:** 5 yılın CSV'sinin her birinin farklı delimiter, encoding ve sütun yapısında olması, veri mühendisliğinin ve sağlam veri okuma stratejilerinin önemini gösterdi. `pandas.read_csv()` parametrelerinin esnekliği kritikti.
- **Merge stratejisi projenin bel kemiğidir:** Farklı kurumsal kaynaklardan gelen verileri birleştirirken isim normalizasyonu, regex temizliği ve fuzzy matching kaçınılmazdır. %100 eşleşme nadirdir; kayıp oranını dokümente etmek önemlidir.
- **Basit modeller savunulabilir içgörüler üretir:** Karmaşık modellere gerek kalmadan, iyi bir EDA ve temel regresyon/kümeleme ile politika önerilerine dönüşebilecek anlamlı sonuçlar elde edilebilir.
- **Çok boyutlu analiz değerlidir:** Zamansal (5 yıllık trend) × Mekansal (GPS) × Altyapısal (istasyon özellikleri) × Ağsal (aktarma bağlantıları) boyutların birleşimi, tek boyutlu analizden çok daha zengin içgörüler sunmuştur.
- **Kod gözden geçirme hataları yakalar:** Notebook çalıştırılırken hücre sıralaması hatası, sütun yeniden adlandırma bug'u ve koordinat düzeltme hatası gibi sorunlar tespit edilip düzeltilmiştir. Otomatik doğrulama (verify) ve kod incelemesi (code-review) iş akışın ayrılmaz parçasıdır.

7. Sonuç

Bu çalışma, İstanbul raylı sistemlerinin işleyişine dair veriye dayalı içgörüler sunmaktadır. Haftasonu yolcu düşüşü (%24), aktarma istasyonlarının kritik rolü, Tarihi Yarımada'daki yoğunlaşma ve kısa hatların km başına yüksek verimliliği, ulaşım planlaması için somut çıkarımlardır. Füniküler ve tramvay gibi kısa ama yoğun hatların başarısı, gelecekteki yatırımların uzun metro koridorları yerine yüksek talep gören kısa bağlantılara yönlendirilebileceğini göstermektedir.

Proje, veri bilimi iş akışının (veri toplama → temizleme → keşifsel analiz → modelleme → yorumlama → raporlama) gerçek dünya verisi üzerinde başarılı bir uygulamasıdır. İBB Açık Veri Portalı'ndaki veri setlerinin birleştirilmesiyle elde edilen çok boyutlu analiz, İstanbul ulaşım planlaması için veriye dayalı karar destek potansiyeli taşımaktadır.